Informatica

Dario Pescini[1]

Università degli Studi di Milano-Bicocca

Dipartimento di Statistica e Metodi Quantitativi

dario.pescini@unimib.it

Cos'è l'informatica

https://www.wooclap.com/NQJSXT

Cos'è l'informatica

- Informatica = Informazione + Automatica
- Scienza della rappresentazione e dell'elaborazione dell'informazione
- Studio delle tecnologie e conoscenze che permettono di
  - elaborare (trasformare)
  - memorizzare
  - distribuire

  l'informazione

Chi è lo statistico?

https://www.wecanjob.it/archivio2_statistico_0_199.html

Chi è e di cosa si occupa lo Statistico?

"Lo Statistico raccoglie, analizza e interpreta i dati numerici. Può lavorare presso centri di ricerca, Università, enti pubblici o imprese private (nel dipartimento ricerca e sviluppo o nel centro studi)."

https://www.wecanjob.it/archivio2_statistico_0_199.html

Perchè lo statistico usa l'informatica?

https://www.wooclap.com/NQJSXT

Il lavoro dello Statistico è così strutturato:

- sulla base delle analisi che deve condurre, studia l'esatto ambito dell'indagine e seleziona il campione identificativo e le variabili di riferimento.
- A questo punto, definisce le metodologie di raccolta dei dati più idonee (questionari, interviste, ecc.)
- Utilizzando appositi software di calcolo e di gestione di data base, elabora i dati raccolti e verifica eventuali nessi di causalità tra i fenomeni esaminati. Predispone grafici e tavole statistiche.
- Successivamente, formula stime e previsioni e interpreta e diffonde i risultati emersi.

Svolge le sue attività in un team di ricerca. Maturata una certa esperienza nel settore e acquisite competenze manageriali, può dirigere e coordinare lo staff impegnato nelle attività di analisi.
Lo Statistico è una persona dotata di ottime abilità matematiche, statistiche e informatiche. Inquadra e risolve le questioni seguendo un approccio logico e coerente.

https://www.wecanjob.it/archivio2_statistico_0_199.html

Perchè informatica a SGI?

Obiettivi formativi e competenze attese

Il corso di laurea in Statistica e Gestione delle Informazioni si propone di fornire le conoscenze teoriche, le competenze operative e le abilità pratiche per **rilevare, gestire e trattare dati qualitativi e quantitativi**, al fine di descrivere e interpretare fenomeni reali in ambiti gestionali, ambientali, demografico-sociali e biomedici. A tal fine offre una solida preparazione generale nei metodi statistici, **fortemente integrata con lo strumento informatico**.

STATISTICA E GESTIONE DELLE INFORMAZIONI 18/19 - Laurea triennale (DM 270) | Università degli Studi di Milano-Bicocca

Perchè informatica a SGI?

Obiettivi formativi e competenze attese

Per quanto riguarda l'Area informatica, si acquisiscono nozioni avanzate sui software di tipo statistico e sul loro utilizzo in presenza di grandi quantità di dati.
Il laureato possiede le competenze necessarie per l'interrogazione di basi di dati, la gestione dei dati, la loro elaborazione mediante la programmazione e l'utilizzo di pacchetti/linguaggi statistici.

STATISTICA E GESTIONE DELLE INFORMAZIONI 18/19 - Laurea triennale (DM 270) | Università degli Studi di Milano-Bicocca

Perchè informatica a SGI?

Il laureato in Statistica e Gestione delle Informazioni è in grado di svolgere i seguenti compiti:

…

`Area informatica`

Operare con software statistici su grandi database, estraendo i dati, preparandoli per l'analisi e successivamente elaborandoli `anche con software e algoritmi sviluppati ad hoc`. Reperire dati statistici, ricorrendo alle varie fonti disponibili tramite l'utilizzo di sistemi informativi e reti telematiche, riconoscendone la pertinenza e la validità.

STATISTICA E GESTIONE DELLE INFORMAZIONI 18/19 - Laurea triennale (DM 270) | Università degli Studi di Milano-Bicocca

Lo statistico usa l'informatica per

- reperire le informazioni
- gestire le informazioni
- manipolare le informazioni
- rappresentare le informazioni

Cosa sono i dati?

https://www.wooclap.com/NQJSXT

Dati ed informazione

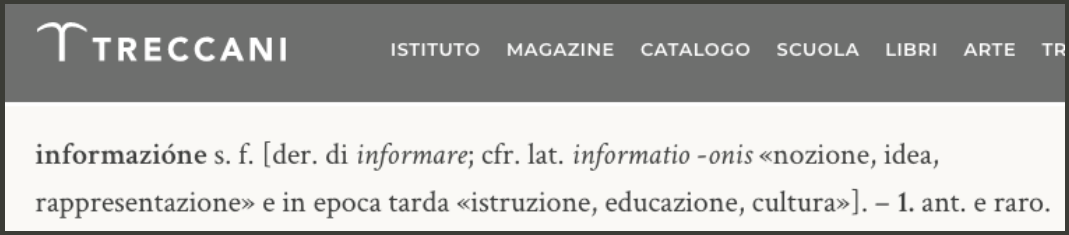

link

Dati ed informazione

- Rappresentare le informazioni: i dati e la codifica
- Ottenere le informazioni: le fonti dei dati
- Gestire i dati
- Analizzare i dati: estrarre le informazioni
- (Rap)presentare le informazioni

Dati ed informazione

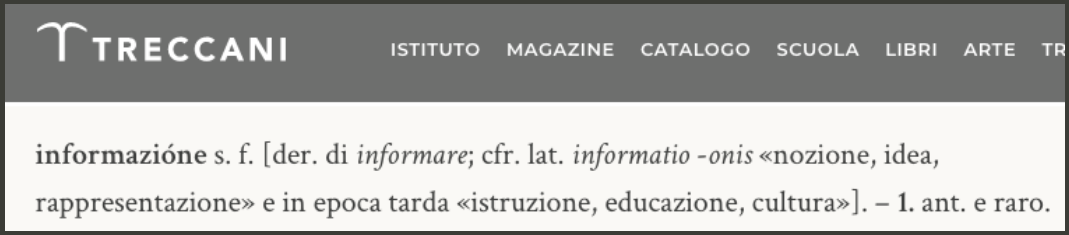

link

informazióne s. f. [der. di informare; cfr. lat. informatio -onis «nozione, idea, rappresentazione» e in epoca tarda «istruzione, educazione, cultura»].

Dati ed informazione

Dati ed informazione

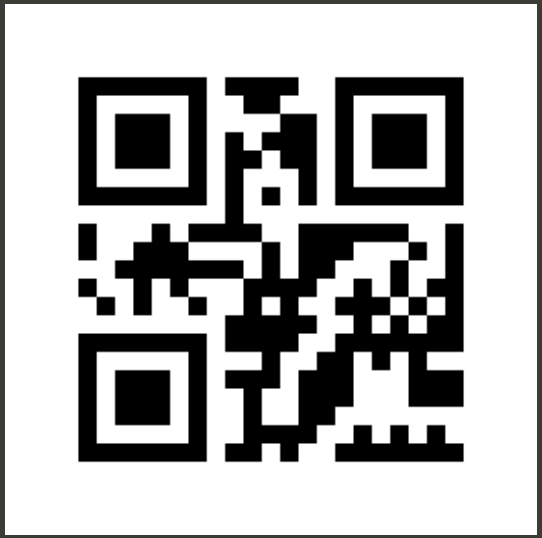

Dati ed informazione

1111001 11*11 121

Dati ed informazione

`1111001` `11*11` `121`

Diverse rappresentazioni della stessa informazione 121

Dati ed informazione

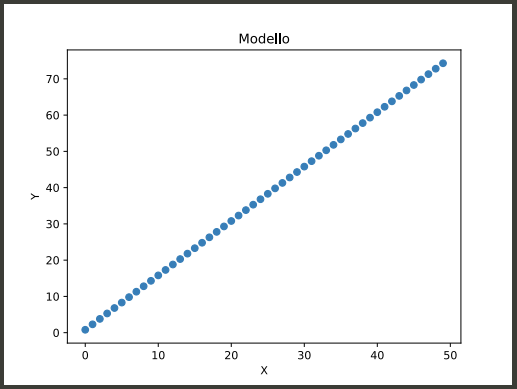


```
( 0 , 0.8 )
( 1 , 2.3 )
( 2 , 3.8 )
( 3 , 5.3 )
( 4 , 6.8 )
...
( 30 , 45.8 )
( 31 , 47.3 )
```

Anche molti `dati` codificati similarmente, trasportano `informazione`.

Alcune fonti dei dati

sono pensate per il trattamento dei dati:

- Istruzione:
  - Portale open data dell'istruzione terziaria
  - Portale Unico dei Dati della Scuola - MIUR
- Regioni:
  - Open Data Regione Lombardia
  - Open Data Regione Toscana
- Pubblica Amministrazione:
  - i dati aperti della pubblica amministrazione
  - ISTAT
- collezioni libere:
  - Our world in data
- ...

Alcune fonti dei dati

altre non saranno pensate per essere facilmente accessibili ma conterranno le informazioni che vi servono...

400 stile libero femminile - Categoria Under 25

1	BAIGUERA MARTA ISIDE	1994	Verolanuoto	4'49"74	0,00
2	FERRARI ALICE	1997	Coopernuoto	4'55"15	0,00

400 stile libero femminile - Categoria Master 25 Tempo Base : 4'23"38

1	GUARESCHI MARTINA	1990	Coopernuoto	4'33"59	962,68
2	FE' ELEONORA	1989	Prosport Acqua ssd	4'52"72	899,77
3	PASTORE GIULIA	1991	Effetto Sport - Barzano'	4'56"77	887,49
4	MOTTADELLI ANNA	1992	Nord Padania Nuoto - Vare	5'03"97	866,47
5	LOPPI LAURA	1989	Amici Nuoto Firenze	5'06"75	858,61
6	BIGIOGGERO GIORGIA	1993	NUOTO ALTO MILANESE	5'19"51	824,32
7	RICCARDI FIORELLA	1989	Amici Nuoto Firenze	5'39"61	775,54

400 stile libero femminile - Categoria Master 30 Tempo Base : 4'22"11

1	LUGANO DILETTA	1984	Derthona Nuoto	4'51"39	899,52
2	TAINI RAFFAELLA	1984	Nuoto Master Brescia asd	5'05"49	858,00
3	COGO MARTINA GAIA	1985	Effetto Sport - Barzano'	5'08"50	849,63
4	PELIZZARI VALENTINA	1987	Aquatic Center ssd	5'26"82	802,00
5	LEONI SARA	1985	Prosport Acqua ssd	5'49"83	749,25
6	LEONARDI CHIARA	1985	ASA asd - Cinisello Balsa	6'07"73	712,78
7	MAZZOLENI ELISA	1987	Canottieri Baldesio	6'31"91	668,80

Informatica?

Informatica!

Supponiamo di voler calcolare il percorso più breve tra due luoghi.

Informatica - realtà e rappresentazione

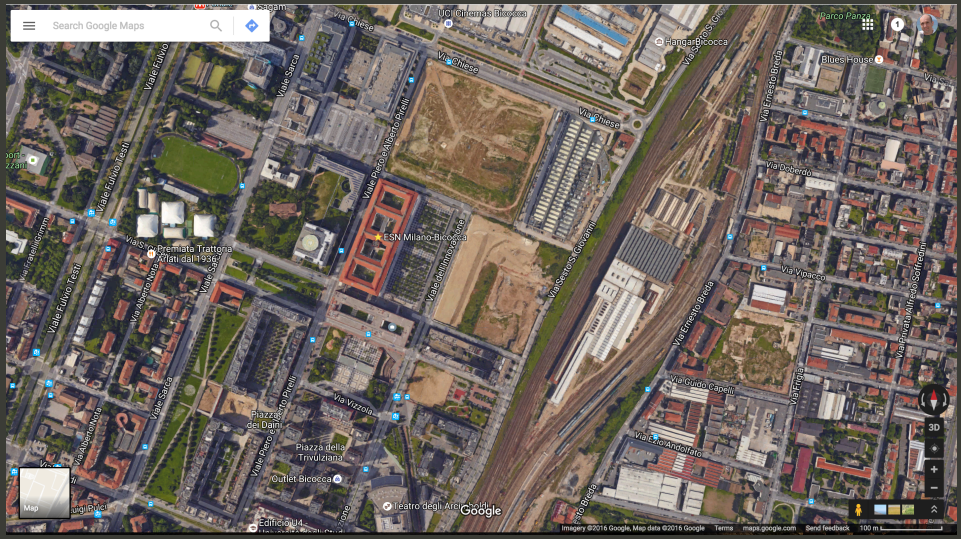
Search Google Maps
Via Chiese
Via Clemente Biscossa
Hangar Bicocca
Parco Parco
Blues House
Via Ercole Bonafous
Via Pirelli
Via Roberto
Via Vipacco
Via Ernesto Breda
Via Guido Capelli
Via Adolfo Tajo
Via Carlo Valvassori Peroni
Via Vizzola
Via Pietro Mascagni
Via Paolo Frisi
Via Paolo Sarpi
Via Valle Fabio
Via Valle Fabio Filzi
Via Valle Scurò
Via Valle Pasubio
Via Valle Pasubio Alfredo Panzini
Via Valle Pasubio Pietro Pirelli
Via Valle Pasubio Ugo Foscolo
Via Valle Pasubio Vincenzo Monti
Via Valle Pasubio Vittorio Alfieri
Via Valle Pasubio Giuseppe Parini

Informatica - realtà e rappresentazione

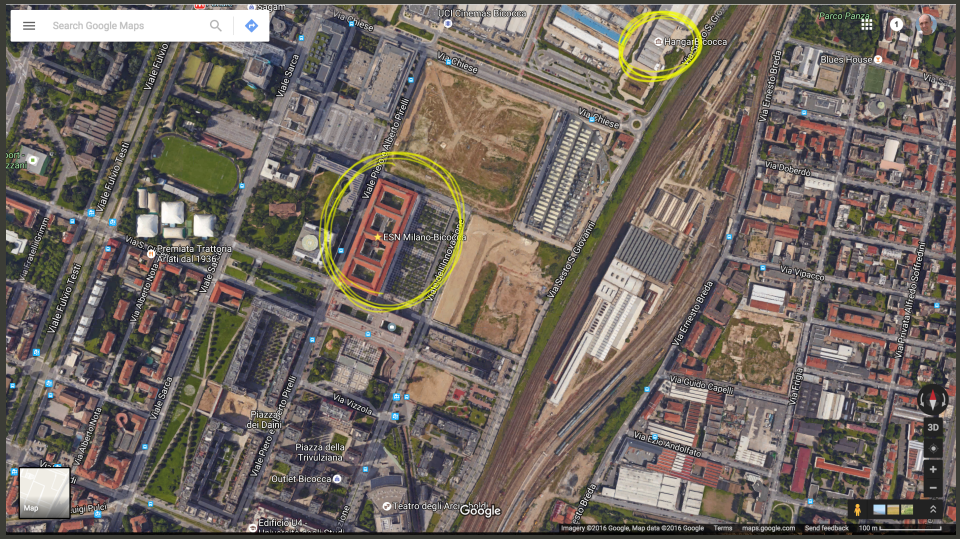

Informatica - realtà e rappresentazione

Dobbiamo trovare una rappresentazione utilizzabile dal calcolatore

Informatica - realtà e rappresentazione

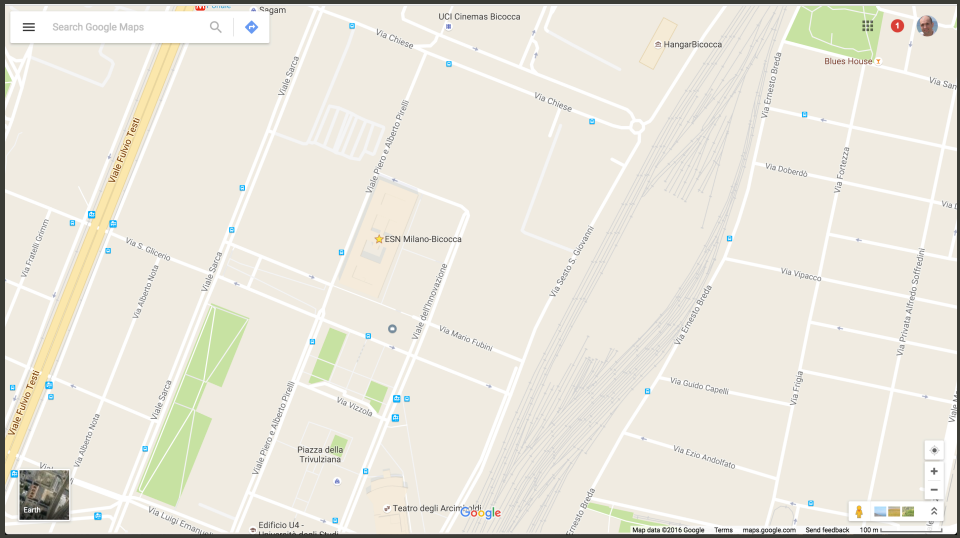

Informatica - realtà e rappresentazione

Che possa essere "codificata" da elementi manipolabili dal calcolatore

Informatica - realtà e rappresentazione

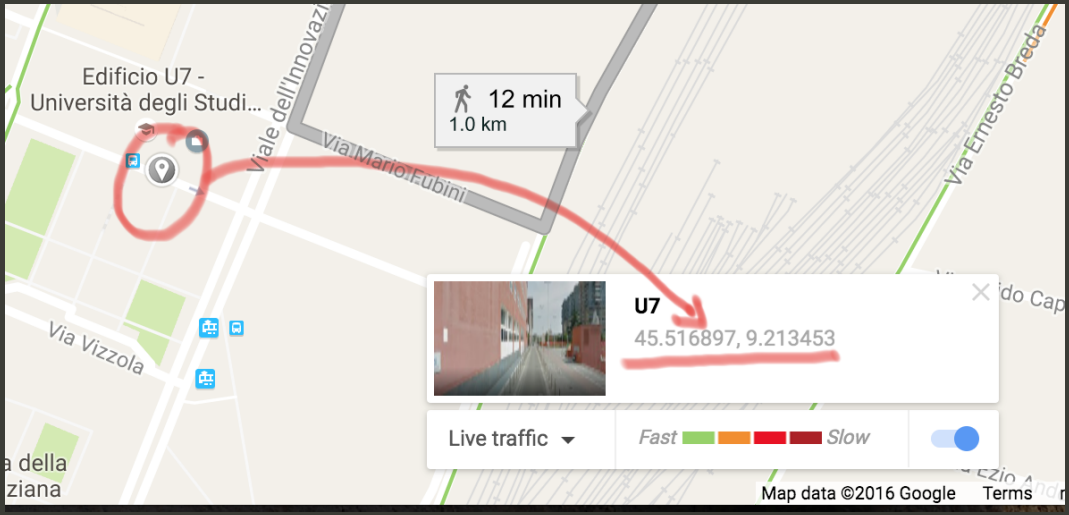

Informatica - realtà e rappresentazione

Ed una serie di operazioni che permattano di ottenere il risultato

Informatica - realtà e rappresentazione

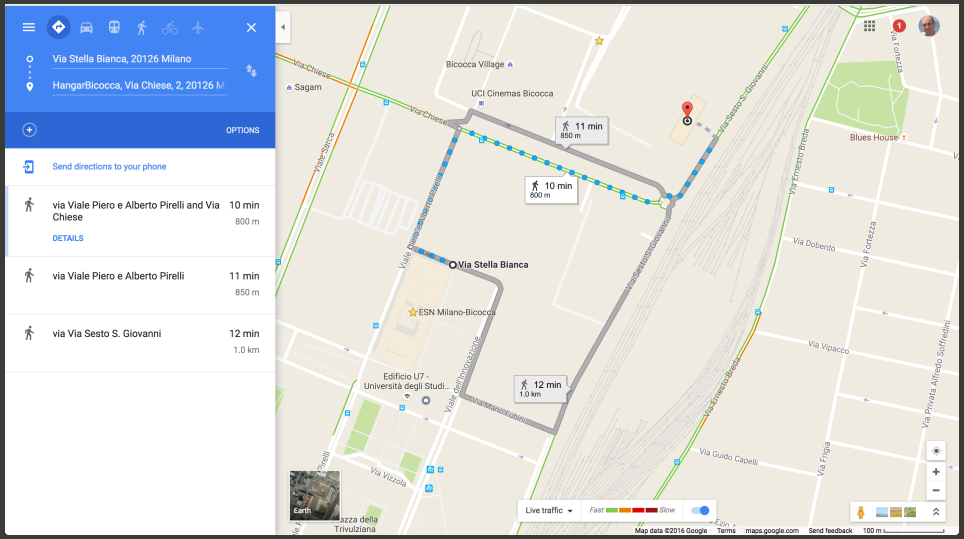

Informatica - realtà e rappresentazione

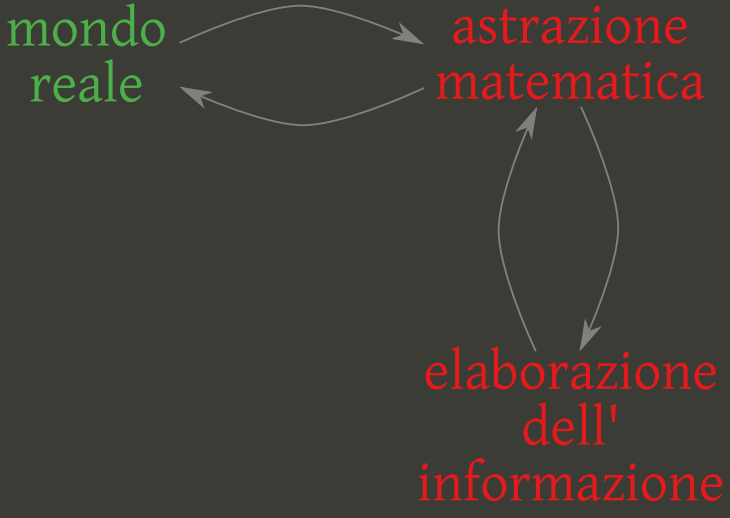

From reality to models

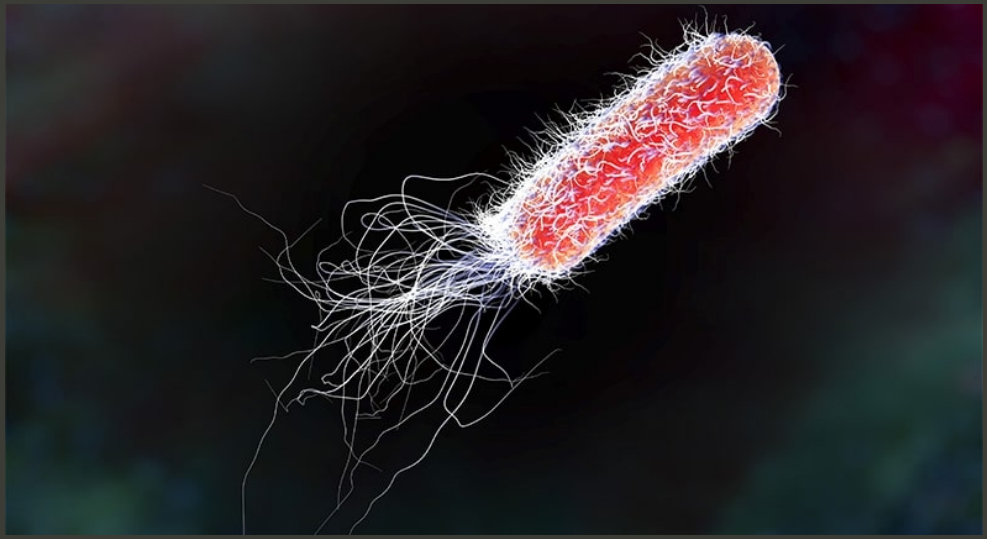

From reality to models

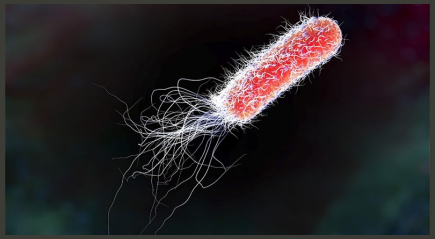

From reality to models

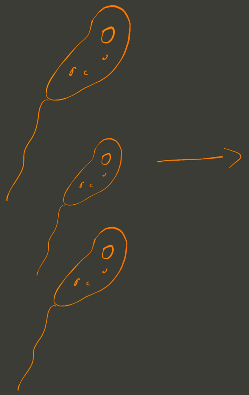

$$\vec{f}(x,t)$$

$$\begin{cases} \dot{\vec{v}} = \dfrac{d\vec{f}(\vec{x},t)}{d\vec{x}} + \dfrac{\partial f(\vec{x},t)}{\partial t} \\ \vec{x}_0 \end{cases}$$

$$y = mx + q$$

From reality to models

$$\vec{f}(\vec{x},t)$$

$$\begin{cases} \dot{\vec{y}} = \dfrac{d\vec{f}(\vec{x},t)}{d\vec{x}} * \dfrac{df(\vec{x},t)}{dt} \\ \vec{x}_0 \end{cases}$$

$$y = mx + q$$

From reality to models

Model Driven

$$\vec{f}(\vec{x},t)$$

$$\begin{cases} \vec{v} = \dfrac{d\vec{F}(\vec{x},t)}{d\vec{x}} + \dfrac{d\vec{F}(\vec{x},t)}{dt} \\ \vec{x_0} \end{cases}$$

$$y = mx + q$$

Data Driven

Model Vs Data -driven

Model driven

- causal description
- hypotheses driven
- build the MODEL then validate on data

Data driven

- learn the model **from** the **DATA**
- working hypothesis: if the data sampling covers all the possible model states, the DATA implicitly contains the model

Model-driven

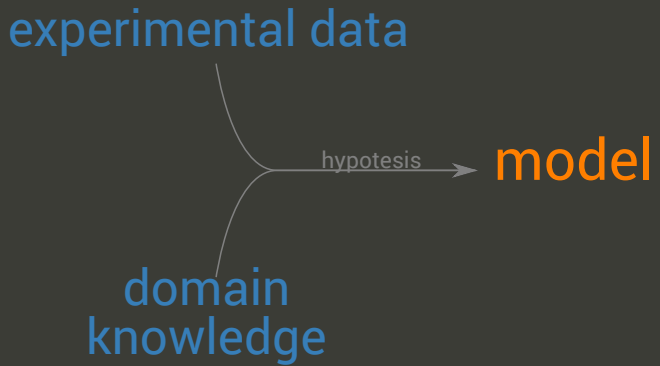

Model-driven

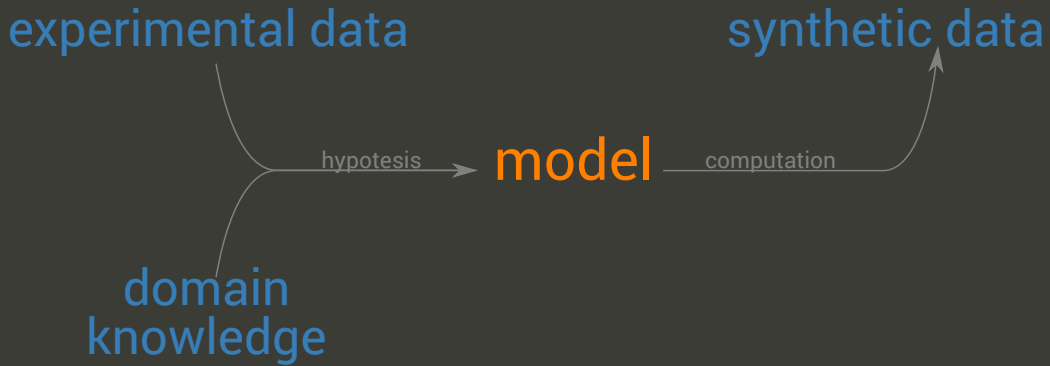

Model-driven

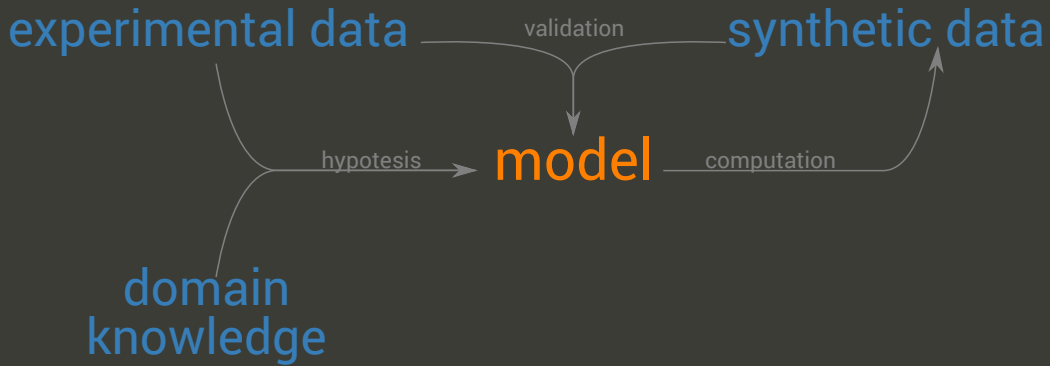

Model-driven

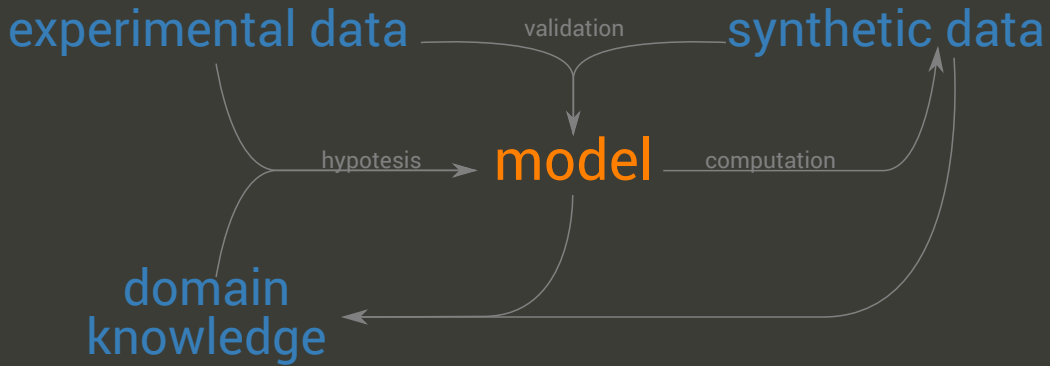

Fenomeno e modello: reazione BZ e il Brusselator

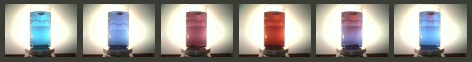

The Brusselator(JCP 46 1695) is a theoretical extremely simplified version (though physically unrealistic) of the BZ (Belousov-Zhabotinskii) Reaction now days recognized as being the prototype for Chemical Oscillators:

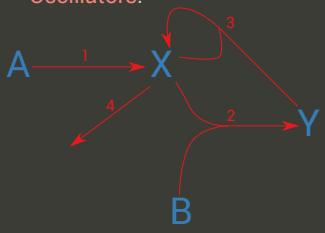

$$A \longrightarrow X$$
$$B + X \longrightarrow Y + D$$
$$2X + Y \longrightarrow 3X$$
$$X \longrightarrow E$$

L'ipotesi biochimica (astrazione)

$$A \xrightarrow{c_1} X$$
$$B + X \xrightarrow{c_2} Y + D$$
$$2X + Y \xrightarrow{c_3} 3X$$
$$X \xrightarrow{c_4} E$$

$$L = \begin{pmatrix} 1 & 0 & 0 & 0 \\ 0 & 1 & 1 & 0 \\ 0 & 2 & 0 & 1 \\ 0 & 1 & 0 & 0 \end{pmatrix} \quad D = \begin{pmatrix} -1 & 1 & 0 & 0 \\ 0 & -1 & -1 & 1 \\ 0 & 1 & 0 & -1 \\ 0 & -1 & 0 & 0 \end{pmatrix} \quad \vec{c} = \begin{pmatrix} 1 \\ 5\,10^{-3} \\ 2.5\,10^{-5} \\ 1.5 \end{pmatrix}$$

Il modello di reazione

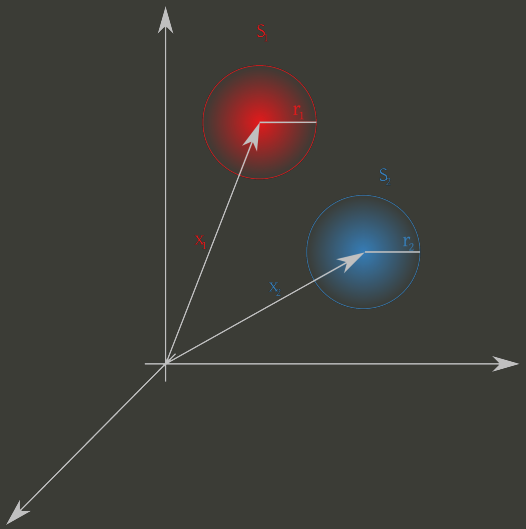

In this framework molecules are “hard-spheres” with radius r_i, position $\overrightarrow{x_i}$ and speed $\overrightarrow{v_i}$

Il modello di reazione

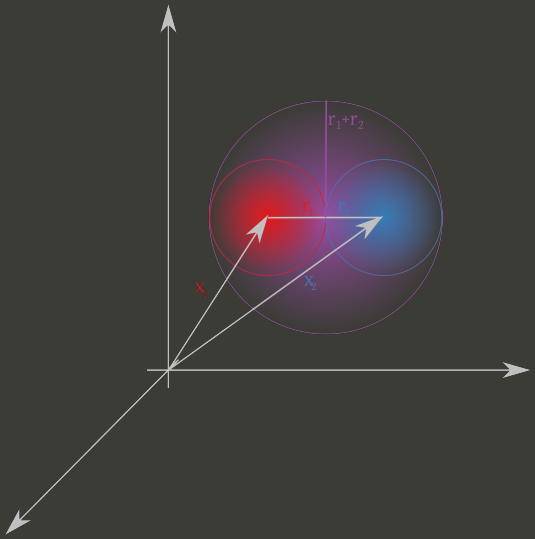

A collision (or reaction) occours whenever the distance of the two centers is

$$d_{1,2} = |\overrightarrow{x_1} - \overrightarrow{x_2}| \leq r_1 + r_2$$

Il modello di reazione

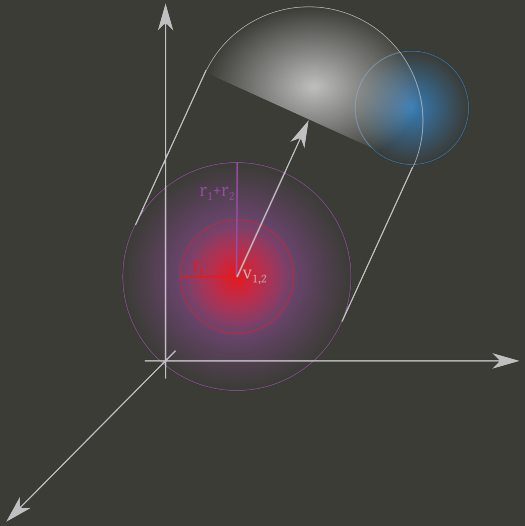

The rate of collisions $S_1 S_2$ will be proportional to the relative speed $\overrightarrow{v}_{1,2}$ of the two moelcules.

Il modello di reazione

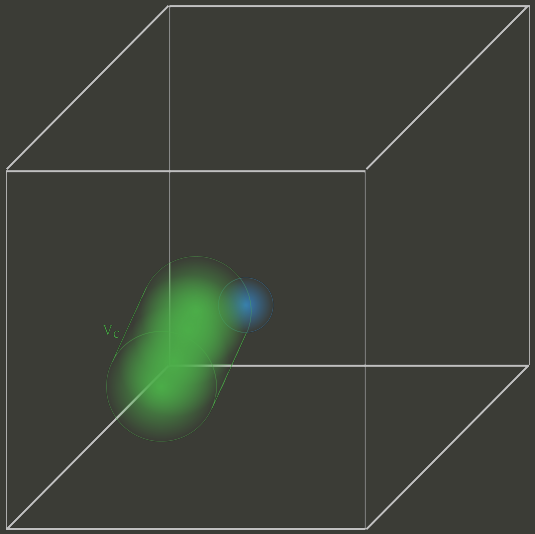

The probability of collision $P_{1,2}$ is related to the probality for molecule 2 to be in δV_c:

$$P_{1,2} = \frac{\delta V_c}{V}$$

Il modello di reazione

Let's start counting the collisions between couples of molecules:

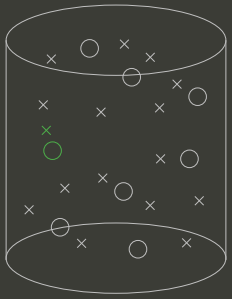

given species X and O there are two possible kinds of couples:

- $X + O \longrightarrow C$ heterologous
- $X + X \longrightarrow C$ homologous

Dal modello all'algoritmo

$\forall$ dynamical step the algorithm answers 2 questions:

- when the next reaction will occur? τ
- which one the next reaction will be? μ

this is done exploiting the Fundamental Hypothesis to get

$P(\tau, \mu)\delta\tau$ = probability that the next reaction in V will occur in the differential time interval $(t + \tau, t + \tau + d\tau)$ and will be R_μ

$P(\mu, \tau) \propto a_\mu = c_\mu h_\mu$ propensity function

c_μ summarizes chemical and physical properties

$h_\mu = \prod_{\substack{1 \\ M}}^{N} \binom{X_i}{\alpha_i}$ combinatorics

$a_0 = \sum_{1}^{\mu} a_\mu$ normalization

SSA: l'algoritmo

for each step of the dynamics:

- compute the probability distribution
- toss r_1

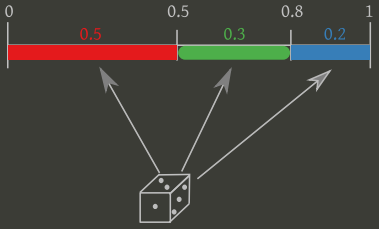

- toss r_2 and compute $\tau = \frac{1}{a_0} \ln \frac{1}{r_2}$
- then apply the tossed rule to modify the number of molecules involved by that rule
- then update the evolution time $t \mathrel{+}= \tau$

dall'algoritmo all'implementazione (in Python)

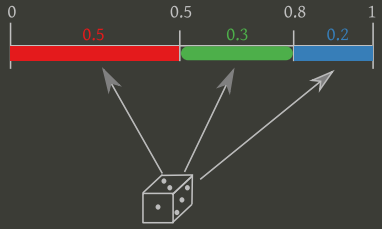


```
def tossRule(propensities, aZero):
    aProbs = propensities / aZero
    rulesSep = aProbs.cumsum( )
    mu = np.where(np.random.random( ) < rulesSep)[0][0]
    return mu
```

dall'implementazione alla descrizione della realtà

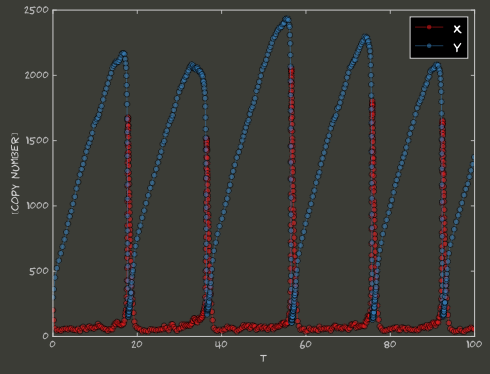


```
0.0000000000E+00 200 300
0.01035677241 192 304
0.01977522782 188 306
0.02975739858 188 309
0.03846115056 182 311
0.05087715559 174 317
0.06179712109 172 320
0.07045694169 166 323
0.08198189597 158 329
0.09113931085 154 333
0.1037595564 146 340
0.1195599116 140 343
0.1328095123 138 346
0.137289434 136 350
0.1481357219 132 353
0.1650723356 136 356
0.1852062628 132 359
0.193735981 124 366
0.2077156606 124 370
0.218739441 120 373
0.2295576964 112 380
0.2410477333 108 385
0.2534414948 106 390
0.2655879618 102 392
0.2767491577 100 395
0.2868282008 100 397
...
```

dall'implementazione alla descrizione della realtà

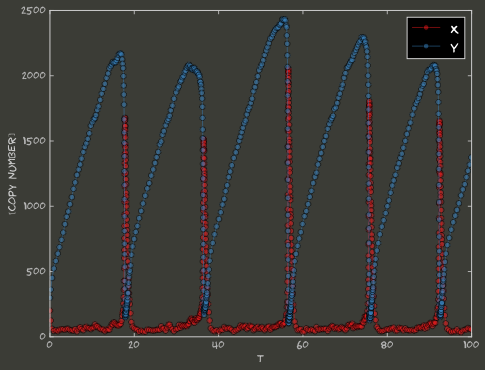

Il modello sembra ben rappresentare la "realtà".

Si può quantifcare l'accuratezza del modello?

Statistica

Quale sarà il vostro contributo come statistici?

- corretta codifica (rappresentazione) dell'informazione per costruire il modello ed il "simulatore"
- guidare nella costruzione dei disegni sperimentali per la successiva analisi dei dati
- estrazione delle informazioni dai dati sperimentali o sintetici

Il vostro strumento sarà l'informatica.

Cosa Studieremo

- La programmazione - Python
- Dati semistrutturati - Python
- Dati strutturati - Focus On Data
  - analisi delle informazioni - Pandas
  - Rappresentazione delle informazioni- Matplotlib

Cosa saprete fare alla fine del corso

Come varierà la distribuzione della popolazione, stratificata per genere, dal 2017 al 2050?

Reperire i dati: sito ISTAT

Reperire i dati: sito Tabella Previsionio 2017

demo istat.it

Vista per: SINGOLA AREA | Area: DOWNLOAD | NOTE

Tipo di interrogazione

Popolazione per età:
Componenti del bilancio demografico:
Indicatori:

Parametri:

Anno: 2018
Età iniziale: 0
Età finale: 110 e oltre
Ripartizione: Italia
Regione:
Tavola

Salva | Stampa

Popolazione per sesso ed età al 1° gennaio 2018 - Italia

Maschi

Età	Limite inferiore intervallo di confidenza al 90% (5° percentile)	Limite inferiore intervallo di confidenza all'80% (10° percentile)	Limite inferiore intervallo di confidenza al 50% (25° percentile)	Scenario mediano	Limite superiore intervallo di confidenza al 50% (75° percentile)	Limite superiore intervallo di confidenza all'80% (90° percentile)	Limite superiore intervallo di confidenza al 90% (95° percentile)
0	234.739	234.739	234.739	234.739	234.739	234.739	234.739
1	243.101	243.101	243.101	243.101	243.101	243.101	243.101
2	250.352	250.352	250.352	250.352	250.352	250.352	250.352
3	258.651	258.651	258.651	258.651	258.651	258.651	258.651
4	263.076	263.076	263.076	263.076	263.076	263.076	263.076
5	274.778	274.778	274.778	274.778	274.778	274.778	274.778
6	280.393	280.393	280.393	280.393	280.393	280.393	280.393
7	288.411	288.411	288.411	288.411	288.411	288.411	288.411
8	292.991	292.991	292.991	292.991	292.991	292.991	292.991
9	295.588	295.588	295.588	295.588	295.588	295.588	295.588
10	295.160	295.160	295.160	295.160	295.160	295.160	295.160
11	295.998	295.998	295.998	295.998	295.998	295.998	295.998
12	294.175	294.175	294.175	294.175	294.175	294.175	294.175
13	296.229	296.229	296.229	296.229	296.229	296.229	296.229
14	293.960	293.960	293.960	293.960	293.960	293.960	293.960
15	292.171	292.171	292.171	292.171	292.171	292.171	292.171
16	295.868	295.868	295.868	295.868	295.868	295.868	295.868
17	302.776	302.776	302.776	302.776	302.776	302.776	302.776
18	302.866	302.866	302.866	302.866	302.866	302.866	302.866
19	311.216	311.216	311.216	311.216	311.216	311.216	311.216
20	309.961	309.961	309.961	309.961	309.961	309.961	309.961
21	310.714	310.714	310.714	310.714	310.714	310.714	310.714
22	309.184	309.184	309.184	309.184	309.184	309.184	309.184
23	311.367	311.367	311.367	311.367	311.367	311.367	311.367
24	316.012	316.012	316.012	316.012	316.012	316.012	316.012
25	328.956	328.956	328.956	328.956	328.956	328.956	328.956
26	327.291	327.291	327.291	327.291	327.291	327.291	327.291
27	334.280	334.280	334.280	334.280	334.280	334.280	334.280
28	331.451	331.451	331.451	331.451	331.451	331.451	331.451
29	339.433	339.433	339.433	339.433	339.433	339.433	339.433
30	331.716	331.716	331.716	331.716	331.716	331.716	331.716
31	333.505	333.505	333.505	333.505	333.505	333.505	333.505
32	343.089	343.089	343.089	343.089	343.089	343.089	343.089

ISTAT Via C. Balbo, 16 00184 Roma

Reperire i dati: Download

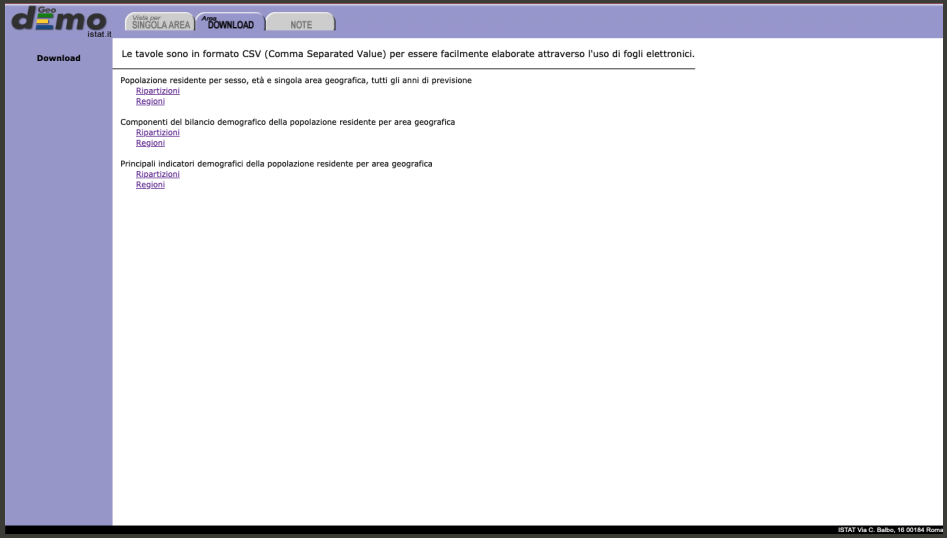

Capire la struttura dei dati

```
"Previsioni probabilistiche della popolazione residente per sesso, età e regione - base 1.1.2017 - Anni 2017/2065"
"Anno: 2017 - Ripartizione: Italia"
"Maschi"
"Età";"Limite inferiore intervallo di confidenza al 90% (5° percentile)";"Limite inferiore intervallo di confidenza all'80% (10° ↪
percentile)";"Limite inferiore intervallo di confidenza al 50% (25° percentile)";"Scenario mediano";"Limite superiore intervallo di ↪
confidenza al 50% (75° percentile)";"Limite superiore intervallo di confidenza all'80% (90° percentile)";"Limite superiore ↪
intervallo di confidenza al 90% (95° percentile)"
0;240100;240100;240100;240100;240100;240100;240100;
1;249511;249511;249511;249511;249511;249511;249511;
2;258236;258236;258236;258236;258236;258236;258236;
....
0;227557;227557;227557;227557;227557;227557;227557;
1;235772;235772;235772;235772;235772;235772;235772;
2;243842;243842;243842;243842;243842;243842;243842;
3;248792;248792;248792;248792;248792;248792;248792;
....
```

Costruisco il grafico per il 2017

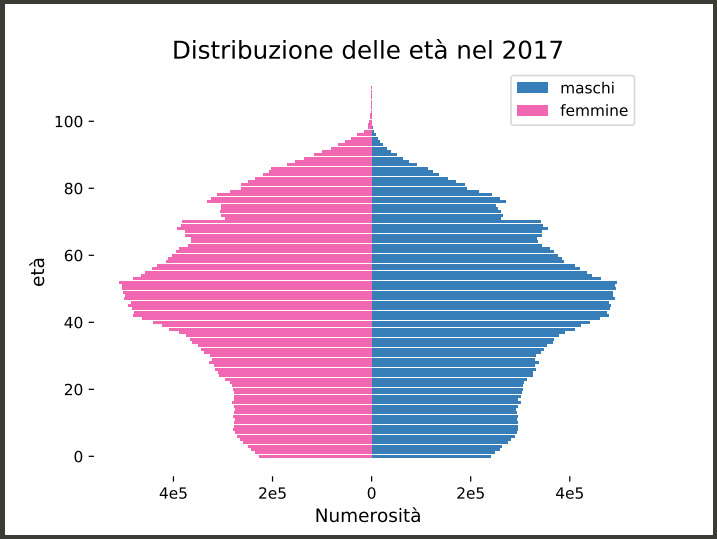

Aggiungo quello per il 2050